1. 背景机制调研

1.1 VLA 机械臂动作预测中的数据冗余问题

视觉-语言-动作模型（Vision-Language-Action, VLA）旨在将环境视觉观测、自然语言指令和机器人状态信息映射为底层动作控制信号，是具身智能机器人实现端到端操作决策的重要技术路径。在机械臂操作任务中，VLA 模型通常需要处理连续图像帧、语言任务描述以及机械臂关节或末端执行器状态，并预测下一步动作或一段动作序列。

然而，真实机器人操作数据并不总是高效的监督信号。人类遥操作采集的数据往往包含大量冗余和噪声，主要体现在以下三个方面。

第一是时序冗余。机械臂执行一个操作任务时，相邻帧之间的图像变化通常较小，尤其是在移动前的等待阶段、接近物体的缓慢运动阶段，或者操作完成后的稳定阶段，大量连续帧携带的信息高度重复。如果直接使用所有帧进行训练，会导致模型反复学习相似样本，增加计算开销，但对动作预测性能的提升有限。

第二是分布冗余。机器人数据集中不同动作阶段的样本分布并不均衡。例如，在抓取任务中，“接近物体”和“保持移动”这类简单状态可能占据较大比例，而真正影响任务成败的关键状态，如接触物体、夹爪闭合、物体被移动、目标放置等，出现次数相对较少。如果训练数据过度集中在简单状态，模型可能对关键操作阶段学习不足。

第三是次优噪声。人类遥操作数据中可能包含犹豫、微调、回退、抖动甚至轻微错误动作。这些数据虽然来自成功轨迹，但并非每一帧都对学习稳定控制策略有正向作用。对于轻量级模型而言，过多低效或噪声样本可能会干扰动作回归，使模型学习到不稳定的动作映射。

因此，在低算力条件下，与其直接扩大数据规模，不如优先筛选高价值样本。核心集选择的目标是在尽可能小的数据子集上保留原始数据中的关键分布、关键动作状态和高信息量变化，从而减少训练成本，同时维持甚至提升模型性能。

1.2 核心集选择与数据修剪思想

核心集选择（Coreset Selection）是一类从大规模数据集中选取代表性子集的方法。其基本思想是：并非所有训练样本对模型学习的贡献相同，部分样本可能高度重复，部分样本可能包含更强的判别信息或更关键的决策边界。通过筛选代表性强、信息量高、覆盖性好的样本，可以在较小数据规模下获得接近甚至优于全量数据的训练效果。

在机器学习中，核心集选择通常关注两个目标：一是代表性，即被选出的样本应尽量覆盖原始数据分布；二是有效性，即被选出的样本应对模型性能提升更有帮助。对于 VLA 机械臂动作预测任务，核心集选择不能只考虑图像外观是否相似，还需要结合动作变化、语言任务、操作阶段等因素。

具体到 ALOHA 仿真操作数据集，单条轨迹由连续图像、机器人状态和动作标签构成。由于动作预测任务的监督目标是机械臂动作，因此核心集选择应优先保留那些视觉状态发生明显变化、动作标签出现显著变化、或者处于任务关键阶段的样本。例如，机械臂接近方块、夹爪闭合、方块被转移、双臂协同交接等阶段，通常比静止等待或匀速移动阶段更具有训练价值。

因此，本课题中的数据修剪并不是简单删除数据，而是根据“冗余”的定义筛除低信息样本。可以将冗余理解为：某些样本与相邻样本或已有样本在视觉特征、动作标签和任务状态上高度相似，对模型训练提供的新信息有限。核心集选择的关键在于建立可计算的冗余度或信息价值指标。

1.3 脑启发机制一：预测编码与时序过滤

预测编码（Predictive Coding）是认知科学中解释大脑感知机制的重要理论。该理论认为，大脑并不是被动接收外界输入，而是持续根据已有经验和上下文对下一时刻的感官输入进行预测。当真实输入与预测结果高度一致时，神经系统只需要较弱响应；当真实输入与预测发生明显偏差时，预测误差信号会增强，从而引导注意力和认知资源集中到变化显著的位置或时刻。

将这一机制映射到机器人操作数据处理中，可以得到一种时序过滤思想：如果相邻帧之间的视觉特征和动作标签变化很小，则这些帧可以被视为低预测误差样本，信息增量有限；如果某一帧相对于前后帧出现明显变化，则说明该时刻可能对应操作状态转换，应具有较高保留价值。

在 VLA 数据集中，预测编码可以对应以下几类可计算指标：

1. 视觉预测误差：使用冻结的 ResNet-18、CLIP 或其他轻量级视觉模型提取图像特征，计算相邻帧特征差异。如果两帧视觉特征距离很小，说明图像状态基本未变，样本可能存在时序冗余；如果特征距离较大，则说明场景发生明显变化，值得保留。

2. 动作预测误差：计算相邻动作标签之间的差异，例如 7 自由度机械臂动作向量的 L2 距离。如果动作变化很小，则该阶段可能是平稳运动；如果动作变化突然增大，可能对应机械臂转向、夹爪开合、接触物体等关键操作。

3. 状态转移强度：联合考虑视觉特征变化和动作变化。当视觉变化与动作变化同时较大时，该样本更可能处于任务关键阶段，例如接触、抓取或放置。

基于预测编码的核心集选择可以理解为：优先保留高预测误差样本，过滤低变化、高重复的连续帧。这样能够减少无意义的“静止帧”或“相似帧”，使有限的 10% 数据预算更多分配给真正影响动作预测的状态变化。

1.4 脑启发机制二：网状激活系统与效用过滤

网状激活系统（Reticular Activating System, RAS）在生物认知中与觉醒、注意调节和信息筛选有关。面对复杂环境时，人类不会平均处理所有感官输入，而是会根据当前任务目标，将认知资源分配给更重要的信息。例如，在操作物体时，人类视觉注意力往往集中在目标物体、手部动作、接触点和即将发生状态变化的区域，而不是背景中的无关细节。

映射到 VLA 数据集筛选中，RAS 可以启发一种任务效用过滤机制：样本的重要性不只取决于是否发生变化，还取决于这种变化是否与当前任务目标相关。对于机械臂 transfer cube 任务，关键样本应当与方块位置、机械臂末端、夹爪状态和动作转折点高度相关，而背景区域的微小变化或无关视角变化不应被赋予过高权重。

因此，可以将 RAS 机制转化为以下数据选择原则：

第一，优先保留动作效用高的样本。若某一帧对应较大的动作幅度变化、夹爪状态变化或关键关节变化，则该帧更可能包含对动作预测有用的信息。

第二，优先保留任务阶段转换样本。机械臂任务通常可以粗略划分为接近、抓取、转移、放置等阶段。阶段转换附近的样本比阶段内部的重复样本更重要。

第三，避免只根据视觉差异选择样本。某些视觉变化可能来自背景扰动或视角噪声，并不一定对动作预测有帮助。因此，核心集选择应结合视觉特征和动作标签，而不是单独依赖图像特征聚类。

在本课题中，RAS 机制的作用可以概括为：在候选样本中进一步判断哪些样本对动作预测任务更有用，从而实现“任务驱动”的样本筛选。

1.5 从脑启发机制到可实现算法

根据预测编码和 RAS 机制，可以将脑启发核心集选择具体转化为一个可实现的数据评分框架。对于每个时间步样本，计算其信息价值分数：

- 视觉变化分数：表示当前图像特征相对于前后帧的变化程度；
- 动作变化分数：表示当前动作标签相对于前后帧的变化程度；
- 分布代表性分数：表示该样本所在区域是否能够代表一类常见状态；
- 多样性分数：避免选出的样本过度集中在同一阶段或同一视觉模式；
- 任务关键性分数：强调接触、抓取、转向、夹爪变化等关键操作时刻。

一种简单可行的策略是先使用冻结视觉编码器提取每帧图像特征，再计算相邻帧之间的视觉特征差异和动作标签差异。然后根据加权得分对所有样本排序，选择得分最高的一部分样本。同时，为避免只选择少数剧烈变化片段，可以结合聚类方法，在视觉特征空间中进行分组，并在每个聚类中选取得分较高的样本。这样既能保留高信息量样本，也能保证核心集覆盖不同状态分布。

该方法与随机抽样相比具有更强的任务针对性。随机抽样默认所有样本同等重要，可能抽到大量平稳或重复帧；脑启发核心集选择则根据视觉变化、动作变化和任务效用显式定义样本价值，使 10% 数据预算集中在更有训练意义的样本上。

1.6 轻量级 VLA 动作预测中的意义

本课题要求在低算力环境下构建轻量级动作预测模型，例如使用冻结的 ResNet-18 或 CLIP 提取图像特征，再将视觉特征与语言指令组合，训练 MLP 回归机械臂动作。在这种设置下，模型容量有限，无法像大规模 VLA 模型那样依赖海量数据和复杂参数自动吸收冗余。因此，训练数据质量对模型性能的影响更加明显。

如果核心集选择能够有效剔除重复帧、低效帧和噪声帧，那么轻量级 MLP 在相同 10% 数据规模下可能获得更低的动作预测 MSE。这说明数据子集的质量比单纯数据数量更重要，也验证了脑启发机制在机器人学习数据筛选中的实际价值。

从实验角度看，背景机制调研可以支持后续算法设计：随机 10% 抽样作为 baseline，脑启发 10% 核心集作为改进方法，两者使用相同的特征提取器、相同的 MLP 结构和相同的测试集。若核心集方法取得更低 MSE，则说明基于预测误差和任务效用的数据选择策略能够提升轻量级动作预测模型的数据利用效率。

1.7 小结

综上，VLA 机械臂动作预测数据中普遍存在时序冗余、分布冗余和次优噪声。预测编码机制启发我们关注相邻状态之间的变化量，用视觉特征差异和动作差异衡量样本的信息增量；网状激活系统机制启发我们从任务目标出发，优先选择与关键操作阶段相关的高效用样本。将两者结合，可以形成一种脑启发核心集选择方法：在全量数据中筛选出少量但高价值的训练样本，使轻量级模型在低算力条件下获得更有效的动作预测能力。